

Rerankeamento em busca de informações científicas

Tomás M. D. Ueda¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)

tomas.ueda@inf.ufrgs.br

Resumo. *Este trabalho investiga o uso de rerankeamento neural em um sistema de recuperação de informação em duas etapas. O método proposto utiliza o BM25 para recuperar os documentos candidatos mais relevantes e o modelo BGE-Reranker, baseado em cross-encoder, para reordená-los. A avaliação foi realizada em três conjuntos de dados pertencentes ao benchmark BEIR, considerando as métricas nDCG, MRR, Recall e MAP. Os resultados demonstram que o rerankeamento elevou significativamente as métricas em dois dos conjuntos de dados. Entretanto, a variação foi reduzida e não apresentou significância estatística em um dos três. Embora o BGE-Reranker tenha melhorado a qualidade das primeiras posições em dois dos três conjuntos avaliados, sua aplicação aumentou substancialmente a latência das consultas. Conclui-se que o rerankeamento neural pode aprimorar sistemas baseados em BM25, mas sua adoção deve considerar a cobertura da recuperação inicial e o compromisso entre qualidade e custo computacional.*

1. Introdução

Hoje em dia, ferramentas de recuperação de informação estão intrínsecas em nosso cotidiano. Mecanismos de busca na Web, sistemas de gerenciamento de e-mails, assistentes virtuais e aplicações baseadas em Inteligência Artificial Generativa como o Retrieval Augmented Generation (RAG), dependem diretamente da capacidade de localizar, ordenar e apresentar informações relevantes a partir de grandes coleções de documentos. Nesse contexto, a qualidade da recuperação de informação torna-se um fator essencial para que o usuário receba respostas úteis, precisas e alinhadas à sua necessidade de busca.

Tradicionalmente, métodos lexicais como o BM25 são amplamente utilizados em tarefas de busca por sua eficiência e simplicidade. Esse tipo de abordagem considera principalmente a correspondência entre os termos da consulta e os termos presentes nos documentos, sendo bastante eficaz quando as palavras importantes aparecem explicitamente nos textos relevantes. No entanto, essa estratégia pode apresentar limitações quando a consulta exige maior interpretação semântica, quando existem documentos com vocabulário diferente, mas significado semelhante, ou quando documentos lexicalmente parecidos não são necessariamente relevantes.

Com o avanço de modelos neurais de linguagem, técnicas de rerankeamento passaram a ser utilizadas como uma etapa complementar aos mecanismos tradicionais de recuperação. Nessa abordagem, um conjunto inicial de documentos é recuperado por um método como o BM25 e, em seguida, reordenado por um modelo semântico, como o BGE-Reranker. Diferentemente do BM25, o reranker busca avaliar a relação entre

consulta e documento de forma mais contextual, considerando aspectos semânticos que podem não estar evidentes apenas pela sobreposição de palavras.

Este trabalho tem como objetivo realizar um estudo comparativo entre dois pipelines de recuperação de informação em bases científicas: um utilizando apenas BM25 e outro combinando BM25 com BGE-Reranker. Para isso, são utilizados datasets do benchmark BEIR, incluindo SciFact, TREC-COVID e NF-Corpus, permitindo observar o comportamento dos métodos em diferentes cenários de busca científica. A avaliação é conduzida por meio de métricas como nDCG@10, MRR@10, Recall@10 e MAP@10, que permitem analisar tanto a qualidade da ordenação dos documentos quanto a presença de documentos relevantes entre os primeiros resultados.

A partir dessa comparação, busca-se compreender em quais situações o reranking contribui para melhorar os resultados e em quais casos ele pode prejudicar a recuperação. Embora modelos semânticos possam corrigir limitações de abordagens lexicais, eles também podem confundir proximidade temática com relevância real. Dessa forma, o estudo evidencia que o uso de reranking em sistemas de recuperação de informação deve ser analisado de maneira cuidadosa, considerando o domínio dos dados, o custo computacional e o comportamento específico das consultas avaliadas.

2. Referencial Teórico

Esta seção fundamenta os conceitos de Recuperação de Informação (RI) e reranking, detalhando os modelos BM25 e BGE-Reranker, além das coleções e métricas de avaliação adotadas.

2.1. Recuperação de Informação e BM25

A Recuperação de Informação localiza documentos relevantes em grandes coleções textuais a partir de consultas em linguagem natural, mitigando ambiguidades e variações lexicais para ordenar os resultados por relevância [Manning et al. 2008].

O **BM25** é um modelo probabilístico clássico que pontua a relevância documental baseando-se na frequência do termo no documento ($f(t, d)$), na frequência inversa do termo na coleção ($IDF(t)$) e na normalização pelo comprimento do documento ($|d|$) em relação à média ($avgdl$):

$$BM25(q, d) = \sum_{t \in q} IDF(t) \cdot \frac{f(t, d)(k_1 + 1)}{f(t, d) + k_1 \left(1 - b + b \cdot \frac{|d|}{avgdl}\right)}$$

Onde k_1 e b são hiperparâmetros que regulam a saturação da frequência do termo e o grau de penalização pelo tamanho do documento, respectivamente.

2.2. Arquiteturas de Reranking e BGE-Reranker

O reranking em múltiplas etapas combina eficiência e eficácia: um método lexical filtra um subconjunto de candidatos para que, na sequência, um modelo neural reordene o topo do ranking [Nogueira and Cho 2019]. A qualidade do primeiro estágio restringe o pipeline, pois o *reranker* não recupera novos documentos, apenas reorganiza os candidatos fornecidos.

O **BGE-Reranker** implementa uma arquitetura **cross-encoder**. Diferente de modelos de bi-encoders, que geram embeddings independentes, o cross-encoder processa simultaneamente a consulta e o documento [Xiao et al. 2023]. Isso viabiliza interações profundas entre as atenções de todos os tokens envolvidos, otimizando a captura de relações semânticas finas ao custo de maior exigência computacional [BAAI 2024]. Contudo, o modelo pode introduzir ruído ao confundir proximidade temática com relevância.

2.3. Datasets e Julgamentos de Relevância

A validação utiliza o benchmark **BEIR** [Thakur et al. 2021], projetado para avaliar a generalização de modelos de RI em múltiplos domínios através de julgamentos de relevância (*qrels*) padrão. São avaliados três subconjuntos científicos:

- **SciFact**: Verificação de alegações científicas.
- **TREC-COVID**: Busca em literatura médica sobre a COVID-19.
- **NF-Corpus**: Recuperação de informações sobre nutrição e biomedicina.

2.4. Métricas de Avaliação e Análise Estatística

A qualidade do ordenamento no topo do ranking (k) é aferida por quatro métricas complementares:

- **nDCG@k (Normalized Discounted Cumulative Gain)**: Mede a qualidade do posicionamento dos documentos, penalizando itens relevantes situados em posições baixas e suportando relevância graduada.

$$\text{nDCG@}k = \frac{\text{DCG@}k}{\text{IDCG@}k} \quad (1)$$

Onde o cálculo do $\text{DCG@}k$ é definido por:

$$\text{DCG@}k = \sum_{i=1}^k \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)} \quad (2)$$

- **MRR@k (Mean Reciprocal Rank)**: Avalia o inverso multiplicativo da posição do primeiro documento relevante retornado, refletindo a rapidez com que o sistema entrega uma resposta útil.

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (3)$$

Onde $|Q|$ é o tamanho total do conjunto de consultas e rank_i é a posição do primeiro documento relevante para a consulta i .

- **Recall@k**: Determina a cobertura do sistema calculando a fração de documentos relevantes identificados até a posição k em relação ao total de relevantes da consulta.

$$\text{Recall@}k = \frac{|\text{Documentos Relevantes} \cap \text{Top-}k \text{ Recuperados}|}{|\text{Total de Documentos Relevantes}|} \quad (4)$$

- **MAP@k (Mean Average Precision):** Sintetiza precisão e ordenação ao computar a média das precisões acumuladas nos pontos em que cada documento relevante é descoberto.

$$\text{MAP} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \text{AveP}(q) \quad (5)$$

Onde $\text{AveP}(q)$ representa a precisão média para a consulta específica q .

Para verificar se as variações das métricas entre as abordagens são consistentes e não casuais, aplica-se o **Teste Estatístico de Wilcoxon pareado**. Por ser um método não paramétrico, ele avalia a magnitude e o sinal das diferenças par a par por consulta, servindo de suporte rigoroso às análises quantitativas e qualitativas de tamanho de efeito.

3. Metodologia

Este trabalho compara dois pipelines de recuperação de informação (RI) em coleções científicas: a abordagem lexical baseline **BM25** e a abordagem híbrida em duas etapas **BM25 + BGE-Reranker**.

3.1. Visão Geral do Pipeline Experimental




Figura 1. Fluxo do experimento.

O fluxo experimental divide-se em duas configurações (Figura 1):

1. **BM25 (Baseline):** As consultas buscam diretamente no índice lexical, e o ordenamento final baseia-se unicamente no score do BM25.
2. **BM25 + BGE-Reranker:** O BM25 atua como primeiro estágio (filtro), recuperando os 100 candidatos mais relevantes. Na segunda etapa, o modelo neural reordena esses candidatos gerando o ranking final.

Os experimentos foram conduzidos em três datasets obtidos via biblioteca `ir-datasets`, cujas características estão sintetizadas na Tabela 1.

Tabela 1. Resumo dos datasets utilizados.

Dataset	Domínio	Documentos	Consultas Avaliadas
SciFact	Alegações científicas	5.183	300
TREC-COVID	Literatura médica sobre COVID-19	171.332	50
NF-Corpus	Área médica e nutricional	3.633	323

3.2. Preparação dos Dados e Indexação Lexical

Cada documento foi estruturado a partir da concatenação de seu título e corpo textual. As consultas seguiram os splits de avaliação padrão de cada coleção, enquanto os julgamentos de relevância (*qrels*) foram reservados exclusivamente para a validação das métricas.

O texto foi processado por uma tokenização simples (conversão para minúsculas e separação alfanumérica) antes da indexação realizada com a biblioteca `rank-bm25`. No pipeline híbrido, limitar a busca inicial aos 100 melhores candidatos equilibrou a cobertura de documentos relevantes e o custo computacional da etapa subsequente.

3.3. Rerankeamento Semântico

Utilizou-se o modelo `BAAI/bge-reranker-base`, uma arquitetura *cross-encoder* que processa conjuntamente a consulta e o documento, computando uma pontuação que captura interações profundas entre os tokens.

A inferência foi realizada em lotes (com suporte a GPU) sobre os pares formados pela consulta e os 100 candidatos do BM25. Aplicou-se um limite de truncamento de 512 tokens devido às restrições do modelo. O **reranker** apenas reorganiza topologicamente os resultados pré-existentes, sem capacidade de recuperar novos documentos ausentes do conjunto inicial.

3.4. Métricas e Avaliação Experimental

A eficácia dos rankings finais foi mensurada nas profundidades $k \in \{5, 10, 20\}$, reportando-se detalhadamente os resultados para $k = 10$ por meio das seguintes métricas:

- **nDCG@10 (Normalized Discounted Cumulative Gain):** Qualidade da ordenação com base em relevância graduada.

$$\text{nDCG@10} = \frac{\text{DCG@10}}{\text{IDCG@10}} \quad (6)$$

- **MRR@10 (Mean Reciprocal Rank):** Posição do primeiro documento relevante retornado.

$$\text{MRR@10} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (7)$$

- **Recall@10:** Proporção de relevantes recuperados no topo do ranking.

$$\text{Recall@10} = \frac{|\text{Relevantes} \cap \text{Top-10 Recuperados}|}{|\text{Total de Relevantes}|} \quad (8)$$

- **MAP@10 (Mean Average Precision):** Precisão média acumulada.

$$\text{MAP@10} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \text{AveP}_q@10 \quad (9)$$

Adicionalmente, calculou-se o **Candidate Recall@100** para determinar o limite teórico do pipeline híbrido, medindo a fração de documentos relevantes que passaram pelo filtro inicial do BM25.

3.5. Análises Estatística, Qualitativa e de Custo

Para verificar a consistência estatística das variações de $nDCG@10$, aplicou-se o teste pareado de Wilcoxon ($\alpha = 0,05$) comparando os resultados consulta a consulta.

Complementarmente, realizou-se uma análise qualitativa de casos de sucesso e falha do BGE-Reranker em relação ao BM25 para verificar o comportamento do modelo em diferentes cenários semânticos. Por fim, mediu-se a latência computacional por meio do tempo médio de execução por consulta em cada pipeline.

3.6. Ferramentas de Apoio ao Desenvolvimento

Durante o desenvolvimento do trabalho, utilizou-se o Codex [OpenAI 2026], ferramenta de assistência à programação da OpenAI, como apoio em etapas pontuais de implementação, revisão e depuração de trechos de código. O uso da ferramenta concentrou-se principalmente na organização de scripts experimentais, correção de erros de execução e auxílio na estruturação de partes do pipeline de avaliação.

Apesar desse apoio, as decisões metodológicas, a escolha dos datasets, a definição das métricas, a execução dos experimentos, a análise dos resultados e a interpretação crítica dos achados foram realizadas pelo autor. Dessa forma, o Codex foi empregado como ferramenta auxiliar de desenvolvimento, não como fonte de resultados ou de fundamentação teórica.

4. Experimentos e Resultados

Esta seção apresenta a comparação quantitativa e qualitativa entre os pipelines BM25 e BM25 + BGE-Reranker nos datasets NF-Corpus, SciFact e TREC-COVID.

4.1. Resultados Gerais

O BGE-Reranker melhorou as métricas principais no SciFact e TREC-COVID. No NF-Corpus, os resultados foram mistos: houve evolução em $nDCG@10$, $MRR@10$ e $MAP@10$, mas queda no $Recall@10$.

Tabela 2. Comparação entre BM25 e BM25 + BGE-Reranker ($k = 10$).

Dataset	Pipeline	$nDCG@10$	$MRR@10$	$Recall@10$	$MAP@10$
NF-Corpus	BM25	0.3063	0.5090	0.1522	0.2190
	BM25 + BGE	0.3086	0.5273	0.1428	0.2193
SciFact	BM25	0.6519	0.6186	0.7740	0.6070
	BM25 + BGE	0.6949	0.6694	0.8018	0.6541
TREC-COVID	BM25	0.5768	0.7580	0.0153	0.5232
	BM25 + BGE	0.6434	0.8715	0.0163	0.6056

Os ganhos detalhados por dataset, incluindo as diferenças absolutas (Δ) e relativas, estão sintetizados na Tabela 2.

No **NF-Corpus**, o impacto do reranker foi pequeno. A queda de 6,18% no $Recall@10$ indica que o modelo neural deslocou documentos relevantes para fora do top-10. No **SciFact**, os ganhos foram satisfatórios em todas as métricas, impulsionados pela forte

Tabela 3. Análise de ganho detalhada por dataset.

Dataset	Métrica	BM25	BM25 + BGE	Δ Abs.	Δ Rel.
NF-Corpus	nDCG@10	0.3063	0.3086	+0.0023	+0.75%
	MRR@10	0.5090	0.5273	+0.0183	+3.60%
	Recall@10	0.1522	0.1428	-0.0094	-6.18%
	MAP@10	0.2190	0.2193	+0.0003	+0.14%
SciFact	nDCG@10	0.6519	0.6949	+0.0430	+6.60%
	MRR@10	0.6186	0.6694	+0.0508	+8.21%
	Recall@10	0.7740	0.8018	+0.0278	+3.59%
	MAP@10	0.6069	0.6541	+0.0472	+7.78%
TREC-COVID	nDCG@10	0.5768	0.6434	+0.0666	+11.59%
	MRR@10	0.7580	0.8715	+0.1135	+14.97%
	Recall@10	0.0152	0.0163	+0.0001	+7.24%
	MAP@10	0.5232	0.6056	+0.0824	+15.75%

dependência de interpretação semântica das afirmações científicas. O **TREC-COVID** apresentou os maiores avanços relativos (ex: +14,97% em MRR@10). O Recall@10 absoluto permaneceu baixo em ambos os pipelines devido ao elevado número médio de documentos relevantes por tópico neste dataset.

4.2. Significância Estatística, Cobertura e Custo Computacional

Para validar os resultados de nDCG@10, aplicou-se o teste pareado de Wilcoxon ($\alpha = 0,05$). A cobertura da primeira etapa foi medida via Candidate Recall@100 (CR@100), e a eficiência foi avaliada pelo tempo médio por consulta (Tabela 3).

Tabela 4. Significância (nDCG@10), Cobertura (CR@100) e Latência Média.

Dataset	p -value (Wilcoxon)	CR@100	Tempo BM25	Tempo BM25 + BGE
NF-Corpus	0.950775 (n.s.)	0.2359	0.0050 s	3.2497 s
SciFact	0.000466 (*)	0.8731	0.0194 s	3.2984 s
TREC-COVID	0.008778 (*)	0.0936	0.9722 s	4.1153 s

(*) Estatisticamente significativo ($\alpha < 0,05$); (n.s.) não significativo.

As melhorias no SciFact e TREC-COVID são estatisticamente significativas, enquanto o NF-Corpus não apresentou evidências de evolução ($p > 0,05$). O alto CR@100 no SciFact (0.8731) justifica o sucesso do reranker, que encontrou um conjunto inicial rico para reordenar. No TREC-COVID, embora o CR@100 seja baixo pelo volume de relevantes do dataset, o reranker otimizou com eficácia o topo do ranking.

Em contrapartida, o custo computacional aumentou drasticamente com a inferência neural: a latência saltou de milissegundos no BM25 para patamares superiores a 3 segundos por consulta no pipeline combinado, evidenciando um claro *trade-off* entre eficácia e eficiência.

4.3. Análise Qualitativa

Caso Positivo (TREC-COVID): Na consulta “*What are the guidelines for triaging patients infected with coronavirus*”, o BM25 falhou ($nDCG$ e $MRR = 0.000$) ao priorizar documentos com sobreposição lexical estrita, mas focados em contextos irrelevantes (ex: cirurgia endócrina e radioterapia). O BGE-Reranker corrigiu o ranking ($nDCG = 0.469$; $MRR = 1.000$), promovendo documentos semanticamente alinhados sobre caminhos de triagem para COVID-19.




Figura 2. Representação gráfica da query e chunks do caso positivo

Caso Negativo (NF-Corpus): Na consulta “*The Actual Benefit of Diet vs. Drugs*”, o BM25 obteve $nDCG$ de 0.539 e MRR de 1.000. O BGE-Reranker prejudicou o desempenho ($nDCG = 0.084$; $MRR = 0.125$) ao promover documentos com proximidade temática superficial (ex: interações entre frutas e remédios; dietas vegetarianas), mas que desviavam do escopo de relevância estrita do dataset.




Figura 3. Representação gráfica da query e chunks do caso negativo

4.4. Discussão e Síntese

Os experimentos confirmam que o BGE-Reranker é altamente eficaz quando a recuperação inicial (BM25) garante boa cobertura e quando o domínio exige interpretação semântica para evitar falsos positivos lexicais (SciFact e TREC-COVID). Contudo, em cenários onde a busca por palavras-chave já é competitiva ou o modelo neural confunde similaridade temática com relevância direta (NF-Corpus), o reranqueamento pode introduzir ruído.

5. Conclusão

Este trabalho apresentou uma análise comparativa entre dois pipelines de recuperação de informação aplicados a coleções científicas: um baseado exclusivamente no BM25 e outro combinando BM25 com BGE-Reranker. O objetivo principal foi investigar se a adição de uma etapa neural de reranqueamento seria capaz de melhorar a qualidade dos rankings produzidos por um método lexical tradicional.

Os resultados obtidos indicam que o uso do BGE-Reranker trouxe ganhos relevantes em dois dos três datasets avaliados. No SciFact e no TREC-COVID, o pipeline BM25 + BGE-Reranker apresentou melhorias em métricas como $nDCG@10$, $MRR@10$, $Recall@10$ e $MAP@10$, além de diferenças estatisticamente significativas no teste de Wilcoxon. Esses resultados sugerem que o reranqueamento neural é especialmente útil em cenários nos quais a consulta exige maior interpretação semântica ou nos quais a simples correspondência lexical pode recuperar documentos superficialmente semelhantes, mas pouco relevantes.

Por outro lado, os resultados no NF-Corpus mostram que o reranqueamento não garante melhora em todos os casos. Nesse dataset, os ganhos foram marginais e não apresentaram significância estatística, além de haver queda no $Recall@10$. A análise qualitativa reforçou esse comportamento ao mostrar que o BGE-Reranker pode promover documentos semanticamente próximos ao tema da consulta, mas que não correspondem necessariamente à relevância esperada pelos julgamentos do dataset. Dessa forma, o modelo pode confundir proximidade temática com relevância real.

Outro ponto importante observado foi o aumento do custo computacional. Embora o BM25 apresente baixa latência, o pipeline com BGE-Reranker exige inferência neural para cada par consulta-documento, elevando consideravelmente o tempo médio por consulta. Assim, a adoção de reranqueamento em sistemas reais deve considerar o compromisso entre ganho de qualidade e custo de execução.

Conclui-se que o reranqueamento neural pode aprimorar sistemas de recuperação de informação baseados em BM25, principalmente quando há boa cobertura na etapa inicial de candidatos e quando o domínio demanda análise semântica mais refinada. Entretanto, seu uso deve ser avaliado com cautela, pois os ganhos variam conforme o dataset, o tipo de consulta e a qualidade da recuperação inicial. Como trabalhos futuros, seria interessante avaliar diferentes quantidades de candidatos iniciais, testar outros modelos de reranqueamento, investigar estratégias seletivas para aplicar o reranker apenas em consultas com maior potencial de ganho e expandir a análise para coleções em língua portuguesa.

Referências

- BAAI (2024). Bge reranker base. Model card: BAAI/bge-reranker-base. Disponível em: Hugging Face.
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Nogueira, R. and Cho, K. (2019). Passage re-ranking with bert. *arXiv preprint arXiv:1901.04085*.
- OpenAI (2026). Codex: Ai coding partner from openai. <https://openai.com/codex/>. Acesso em: 22 jun. 2026.
- Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., and Gurevych, I. (2021). Beir: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. *arXiv preprint arXiv:2104.08663*.
- Xiao, S., Liu, Z., Zhang, P., Muennighoff, N., Lian, D., and Nie, J.-Y. (2023). C-pack: Packed resources for general chinese embeddings. *arXiv preprint arXiv:2309.07597*.